

Informe Final

Predicción de Accidentalidad por Barrio y Hora

Clasificación binaria · Clases desbalanceadas · Datos en SQLite

Curso: Aprendizaje Automático · MCDA 2026-1
Profesores: Pablo Saldarriaga
Integrantes: Simón Botero Villarraga
Julian David Mejia Otalvaro
Miguel Ángel Martínez García
Juan Andrés Montoya Galeano
Jerónimo Piedrahita Franco
Entrega: Mayo 22 de 2026

Índice

1. Resumen Ejecutivo	3
2. Descripción del Problema y de los Datos	3
2.1. Contexto	3
2.2. Pregunta de investigación	3
2.3. Descripción de las tablas	4
2.4. Construcción de la variable objetivo	4
3. Análisis Exploratorio de Datos (EDA)	5
3.1. Distribución temporal	5
3.2. Distribución espacial	7
3.3. Relación entre clima y accidentalidad	7
4. Calidad y Consistencia de los Datos	8
4.1. Consistencia de la marca temporal (TW)	8
4.2. Normalización de nombres de barrios	9
4.3. Duplicados	9
4.4. Valores faltantes	9
4.5. Valores atípicos	10
4.6. Validación del cruce final	10
5. Ingeniería de Características	10
5.1. Variables temporales y festivos	11
5.2. Codificación cíclica (seno/coseno)	11
5.3. Variables históricas por barrio	12
5.4. Codificación de variables categóricas	13
5.5. Selección de variables climáticas	14
6. Modelo Baseline y Problema del Desbalance	14
6.1. Baseline ingenuo	14
7. Estrategias de Balanceo, Modelos e Hiperparámetros	15
7.1. Partición temporal del dataset	15
7.2. Estrategias de balanceo	15
7.2.1. Estrategia 1: Class Weight (<code>class_weight='balanced'</code>)	16

7.2.2. Estrategia 2: Random Undersampling	16
7.3. Familias de modelos evaluadas	16
7.3.1. Regresión Logística	16
7.3.2. Random Forest	16
7.3.3. Gradient Boosting	17
7.4. Resultados comparativos	17
7.5. Estrategia elegida y justificación	18
8. Modelo Final, Umbral y Validación	18
8.1. Selección del umbral de decisión	18
8.2. Métricas finales sobre test	20
8.3. Matriz de confusión	21
8.4. Importancia de variables	22
8.5. Validación cruzada temporal	22
9. Caso de Uso Propuesto y Limitaciones	23
9.1. Caso de uso: sistema de alerta preventiva diaria	24
9.2. Limitaciones	26
9.3. Variables externas que mejorarían el modelo	27
10. Conclusiones y Trabajo Futuro	27
10.1. Conclusiones	27
10.2. Trabajo futuro	28

1. Resumen Ejecutivo

Este informe documenta el desarrollo de un modelo de aprendizaje automático para predecir la ocurrencia de accidentes de tránsito en Medellín, dado un barrio y una hora específicos. El problema se enmarca como una **clasificación binaria con clases severamente desbalanceadas**: menos del 2 % de las combinaciones (barrio, hora) registran accidentes.

Se trabajó con una base de datos SQLite de tres tablas: registros crudos de accidentes, una versión agregada por barrio-hora y mediciones climáticas horarias; sobre las que se realizó un proceso completo de limpieza, análisis exploratorio, ingeniería de características y modelado.

Se compararon tres familias de modelos bajo dos estrategias de balanceo. El modelo seleccionado fue un **Random Forest con `class_weight=balanced`**, cuyo umbral de decisión se ajustó maximizando el F_2 -score para priorizar el *recall*, dado que no detectar un accidente tiene mayor costo operativo que una falsa alarma.

Como caso de uso se propone un **sistema de alerta diaria** que lista los barrios y horas de mayor riesgo, permitiendo a la administración municipal asignar operativos de forma proactiva.

2. Descripción del Problema y de los Datos

2.1. Contexto

Las administraciones municipales necesitan anticipar dónde y cuándo es más probable que ocurra un accidente de tránsito para focalizar operativos, agentes y campañas de prevención. La mayoría de las combinaciones (barrio, hora) no presentan accidentes, lo que configura un problema de **clases desbalanceadas** por naturaleza.

2.2. Pregunta de investigación

¿Cuál es la probabilidad de que ocurra al menos un accidente en el barrio B a la hora h del día?

2.3. Descripción de las tablas

Cuadro 1: Tabla `raw_accidentes`: registro individual de cada accidente

Columna	Descripción
TW	Fecha-hora truncada a la hora
FECHA, HORA	Fecha y hora originales del accidente
Hora_num	Hora del día (0–23)
Dia, Mes	Componentes del calendario
BARRIO, COMUNA	Localización administrativa
Lat, Lon	Coordenadas del accidente
CLASE, GRAVEDAD, DISEÑO	Tipo de accidente, gravedad y diseño vial

Cuadro 2: Tabla `accidentes`: versión agregada por barrio y hora

Columna	Descripción
TW	Marca temporal truncada a la hora
BARRIO	Barrio donde ocurrió el accidente
Lat, Lon	Coordenadas representativas del barrio
Dia_sem	Día de la semana
Mes, Dia, Hora	Componentes de la marca temporal

Cuadro 3: Tabla `clima`: mediciones meteorológicas por barrio y hora

Columna	Descripción
TW, BARRIO	Llaves de cruce con las otras tablas
temperature, apparentTemperature	Temperatura y sensación térmica
humidity, dewPoint	Humedad relativa y punto de rocío
precipIntensity, precipProbability	Intensidad y probabilidad de lluvia
windSpeed, windBearing	Velocidad y dirección del viento
cloudCover, uvIndex, visibility	Nubosidad, índice UV y visibilidad

2.4. Construcción de la variable objetivo

La tabla `accidentes` contiene únicamente las combinaciones (barrio, hora) en que sí ocurrió al menos un accidente. Los casos negativos se obtienen del universo completo de

`clima`, que registra todas las combinaciones disponibles. El *target* se define formalmente como:

$$y = \begin{cases} 1 & \text{si } (\text{BARRIO}, \text{TW}) \in \text{accidentes} \\ 0 & \text{en caso contrario} \end{cases}$$

La unión se realizó mediante un **LEFT JOIN** de `clima` hacia `accidentes` sobre las llaves (`BARRIO`, `TW`), conservando la totalidad del universo climático y asignando 0 a las filas sin correspondencia.

3. Análisis Exploratorio de Datos (EDA)

Antes del proceso de modelado se realizó un análisis exploratorio con el propósito de comprender la estructura temporal, espacial y climática de los datos, identificar patrones iniciales y sustentar las decisiones posteriores de ingeniería de características.

El análisis exploratorio se convierte en una herramienta especialmente importante en problemas de clasificación con clases desbalanceadas, ya que permite identificar si existen señales discriminativas capaces de separar eventos poco frecuentes.

3.1. Distribución temporal

Se analizaron los accidentes desde tres perspectivas: hora del día, día de la semana y mes.

Los resultados mostraron una concentración importante durante franjas horarias asociadas con una alta movilidad urbana: primeras horas de la mañana, horarios laborales y horas pico nocturnas.

Estas tendencias sugieren que la probabilidad de accidentalidad no es uniforme temporalmente y que existe una fuerte dependencia de variables periódicas.




Figura 1: Distribución de accidentes por hora del día.

La figura evidencia ciclos diarios claros asociados a dinámicas de tráfico.




Figura 2: Distribución de accidentalidad por día de la semana.

Se observó una diferencia entre días laborales y fines de semana, indicando que la movilidad urbana modifica el comportamiento de la variable objetivo.




Figura 3: Accidentes agregados por mes.

3.2. Distribución espacial

De las variables geográficas se identificaron barrios y comunas con mayor frecuencia histórica.

La concentración espacial fue heterogénea. Algunos sectores presentaron niveles significativamente superiores.




Figura 4: Barrios con mayor número histórico de accidentes.

Este resultado justifica incluir variables históricas agregadas por barrio.

3.3. Relación entre clima y accidentalidad

Posteriormente se evaluó el comportamiento de variables meteorológicas.

Se analizaron temperatura, precipitación, humedad y visibilidad.




Figura 5: Mapa de correlación entre variables climáticas y accidentalidad.

La precipitación y la visibilidad mostraron señales moderadas de asociación.

4. Calidad y Consistencia de los Datos

Antes de integrar las tablas se verificó la consistencia estructural de cada fuente de datos. Esta etapa es crítica porque errores en las llaves de cruce o inconsistencias en los formatos pueden generar positivos perdidos o casos negativos mal etiquetados, comprometiendo toda la cadena de modelado.

4.1. Consistencia de la marca temporal (TW)

Se verificó que TW estuviera en formato `datetime64[ns]` y truncada a nivel de hora en las tres tablas. Se confirmó que ninguna fila presentara minutos o segundos distintos de cero. Esta comprobación es fundamental porque el cruce entre tablas depende exclusivamente de esta columna junto con BARRIO.

Decisión: Se convirtió TW a `datetime64[ns]` de forma uniforme en las tres tablas antes de cualquier operación de cruce.

4.2. Normalización de nombres de barrios

Se detectaron diferencias en la representación textual del campo `BARRIO` entre las tablas: variaciones por mayúsculas, espacios al inicio o final y caracteres especiales. Estas inconsistencias generaban registros positivos que no encontraban correspondencia en `clima`, perdiéndose como casos negativos erróneos.

Decisión: Se aplicaron transformaciones `strip()` y `upper()` a los nombres de barrio en las tres tablas antes del cruce. Los barrios sin correspondencia residual en `clima` se documentaron y excluyeron del análisis.

4.3. Duplicados

Se buscaron duplicados exactos (todas las columnas) y duplicados en las llaves de cruce (`TW`, `BARRIO`). No se encontraron duplicados exactos en `clima`. En `accidentes` se detectaron registros duplicados en la llave de cruce correspondientes a horas con múltiples accidentes registrados por separado.

Decisión: Se conservó una única fila por combinación (`TW`, `BARRIO`) en `accidentes`, dado que la variable objetivo es binaria: indica si ocurrió *al menos* un accidente, no cuántos.

4.4. Valores faltantes

Las variables climáticas presentaron faltantes aislados en menos del 5 % de los registros, principalmente en `precipIntensity` y `windBearing`.

Decisión: Los valores de precipitación nulos se reemplazaron por cero, asumiendo ausencia de lluvia cuando no hay registro. El resto de variables climáticas se imputaron con la mediana calculada *exclusivamente* sobre el conjunto de entrenamiento, aplicando la misma mediana a validación y test. Se eligió la mediana sobre la media por su robustez frente a las distribuciones asimétricas características de variables como `windSpeed` o `precipIntensity`.




Figura 6: Porcentaje de valores faltantes por variable en el dataset integrado.

4.5. Valores atípicos

Se aplicó el criterio IQR para detectar valores fuera del rango $[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$ en las variables climáticas numéricas.

Decisión: Se conservaron los valores extremos en variables como `precipIntensity` y `windSpeed`. Estos valores no son errores de medición sino eventos meteorológicos reales (tormentas, vientos fuertes) que podrían tener una relación genuina con la accidentalidad. Eliminarlos o capearlos introduciría sesgo en la dirección equivocada.

4.6. Validación del cruce final

Se verificó cuántos positivos originales de `accidentes` se conservaron en el dataset final tras el LEFT JOIN con `clima`.

Decisión: Un porcentaje menor de positivos se perdió por inconsistencias residuales en nombres de barrio no resueltas por la normalización textual. Este porcentaje fue documentado y no afecta materialmente el análisis dado el volumen total del dataset.

5. Ingeniería de Características

5.1. Variables temporales y festivos

A partir de la marca temporal TW se extrajeron las siguientes variables: hora del día, día del mes, mes, año, día de la semana, día del año, indicador binario de fin de semana e indicador binario de festivo colombiano mediante la librería `holidays`.

La inclusión de festivos se justifica porque alteran los patrones de movilidad urbana de forma sistemática y predecible: el comportamiento del tráfico en un festivo se asemeja más al de un domingo que al del día de la semana que corresponde en el calendario.

5.2. Codificación cíclica (seno/coseno)

Las variables temporales son inherentemente periódicas. La hora 23 y la hora 0 son consecutivas en el tiempo, pero numéricamente distan 23 unidades. Si se usan directamente como variables numéricas, los modelos lineales y basados en distancia perciben una discontinuidad artificial que no existe en la realidad.

La solución es proyectar cada variable al círculo unitario mediante la transformación seno/coseno:

$$\sin_hora = \sin\left(\frac{2\pi \cdot hora}{24}\right), \quad \cos_hora = \cos\left(\frac{2\pi \cdot hora}{24}\right)$$

El mismo esquema se aplicó a `dia_sem` (periodo 7), `mes` (periodo 12) y `dia_anio` (periodo 365). Con esta representación, la distancia entre hora 23 y hora 0 en el espacio (sin, cos) es mínima, preservando la continuidad real del fenómeno.




Figura 7: Representación lineal vs. cíclica de la hora del día. En la representación lineal existe un salto artificial entre las 23h y las 0h que no existe en la realidad.

5.3. Variables históricas por barrio

La frecuencia histórica de accidentes en un barrio es una señal predictiva muy poderosa: un barrio con alta accidentalidad histórica tiene más probabilidad de registrar un accidente en cualquier hora futura que un barrio sin antecedentes.

El cálculo directo de esta estadística sobre todo el dataset introduce fuga de información temporal, causando que la fila correspondiente al instante T viese datos del futuro, lo que produce métricas de validación irrealmente optimistas e inutiliza el modelo en producción.

Solución aplicada: para cada fila en el instante T , las estadísticas históricas se calcularon usando únicamente observaciones con $TW < T$, mediante `shift(1).expanding()` dentro de cada grupo de barrio, sobre el dataset ordenado cronológicamente. Las primeras filas de cada barrio sin historial disponible recibieron la media global como valor por defecto.

Las variables creadas fueron:

- `tasa_hist_barrio`: proporción histórica de horas con accidente en el barrio hasta T .
- `tasa_hist_barrio_hora`: ídem, pero segmentado adicionalmente por hora del día, capturando patrones horarios específicos de cada barrio.
- `acc_hist_acum`: conteo acumulado absoluto de accidentes en el barrio hasta T .

5.4. Codificación de variables categóricas

Cuadro 4: Esquema de codificación de variables categóricas

Variable	Codificación	Justificación
BARRIO, summary, icon	Frecuencia	One-hot generaría cientos de columnas esparsas. Target encoding requiere recalcularse en cada fold. La frecuencia es un proxy seguro que captura cuán representada está cada categoría sin introducir leakage.
comuna	Frecuencia	Cardinalidad media, mismo razonamiento anterior.
periodo_dia	One-hot	Solo 4 categorías (madrugada, mañana, tarde, noche).

Los mapeos de frecuencia se calcularon exclusivamente sobre el conjunto de entrenamiento y se aplicaron luego a validación y test, evitando que información de estos conjuntos influya en la codificación.

5.5. Selección de variables climáticas

Cuadro 5: Variables climáticas incluidas, excluidas y justificación

Variable	Decisión	Justificación
humidity	Incluida	Distribución diferente entre clases en el EDA
precipIntensity, precipProbability	Incluidas	Correlación positiva con accidentalidad
visibility	Incluida	Menor visibilidad implica mayor riesgo
windSpeed	Incluida	Afecta el control del vehículo
temperature	Incluida	Contexto térmico general
cloudCover	Incluida	Señal de condición meteorológica
apparentTemperature	Excluida	$r > 0.97$ con <code>temperature</code> : redundante
dewPoint	Excluida	Función directa de temperatura y humedad
uvIndex	Excluida	Proxy de hora del día, ya codificada cíclicamente
windBearing	Excluida	Sin relación causal directa con accidentalidad

6. Modelo Baseline y Problema del Desbalance

6.1. Baseline ingenuo

Antes de entrenar cualquier modelo real se construyó un `DummyClassifier` configurado para predecir siempre la clase mayoritaria (0 = sin accidente). Su propósito es establecer el piso mínimo de desempeño y demostrar por qué la *accuracy* no es una métrica válida en este contexto.

Cuadro 6: Resultados del DummyClassifier

Métrica	Valor	Interpretación
Accuracy	0.9828	Alta, pero completamente engañosa
Recall	0.0000	Ningún accidente detectado
F1	0.0000	Sin capacidad predictiva real

Un modelo que nunca predice accidentes obtiene 98 % de exactitud simplemente porque el 98.5 % de los casos son negativos. Este resultado confirma que la accuracy no puede usarse como métrica principal y que las métricas relevantes para este problema son: Recall, F_2 , ROC-AUC y PR-AUC.

7. Estrategias de Balanceo, Modelos e Hiperparámetros

7.1. Partición temporal del dataset

El dataset se dividió en tres conjuntos usando corte cronológico estricto, sin aleatorización. En datos con dependencia temporal, mezclar filas de distintos momentos introduciría fuga de información: el modelo vería el futuro durante el entrenamiento.

Cuadro 7: Partición temporal del dataset

Conjunto	Proporción	Uso
Train	70 %	Entrenamiento y balanceo
Validación	15 %	Selección de estrategia, modelo y umbral
Test	15 %	Evaluación final

7.2. Estrategias de balanceo

Se compararon dos estrategias para mitigar el desbalance 1:65.

7.2.1. Estrategia 1: Class Weight (`class_weight='balanced'`)

Ajusta automáticamente el peso de cada clase en la función de pérdida del modelo:

$$w_i = \frac{n_{\text{total}}}{n_{\text{clases}} \cdot n_i}$$

El modelo penaliza más los errores sobre la clase minoritaria sin modificar los datos. Es la estrategia de menor costo computacional y sin riesgo de leakage por re-muestreo.

7.2.2. Estrategia 2: Random Undersampling

Reduce la clase mayoritaria eliminando aleatoriamente filas del conjunto de entrenamiento hasta obtener 5 negativos por cada positivo. Se eligió un ratio 1:5 en lugar de 1:1 porque igualar las clases elimina demasiada información útil de la clase mayoritaria. El undersampling es más rápido que técnicas generativas como SMOTE y suficiente para datasets de este volumen.

7.3. Familias de modelos evaluadas

Se compararon tres familias de modelos con naturalezas fundamentalmente distintas.

7.3.1. Regresión Logística

Modelo lineal que estima la probabilidad de la clase positiva mediante la función sigmoide aplicada a una combinación lineal de las features. Es interpretable, rápido y sirve como referencia para evaluar si las relaciones en los datos son capturables sin no-linealidad. Sus hiperparámetros principales son la regularización C (inverso de la intensidad) y el tipo de penalización.

Configuración: `max_iter=1000, solver='lbfgs', random_state=42`.

7.3.2. Random Forest

Ensamble de árboles de decisión entrenados sobre muestras bootstrap del dataset (bagging). Cada árbol usa un subconjunto aleatorio de features en cada nodo, lo que reduce la correlación entre árboles y mejora la generalización. Maneja naturalmente no-linealidades e interacciones entre variables sin requerir transformaciones previas. Sus

hiperparámetros principales son el número de árboles, la profundidad máxima y el mínimo de muestras por hoja.

Configuración: `n_estimators=200, max_depth=10, min_samples_leaf=50, random_state=42, n_jobs=-1`.

7.3.3. Gradient Boosting

Ensamble secuencial donde cada árbol corrige los errores del árbol anterior, minimizando iterativamente una función de pérdida diferenciable. A diferencia del Random Forest, el Gradient Boosting es secuencial y típicamente más preciso pero más lento y propenso a sobreajuste si no se regulariza adecuadamente. Sus hiperparámetros clave son la tasa de aprendizaje, el número de estimadores y la profundidad máxima.

Configuración: `n_estimators=200, learning_rate=0.05, max_depth=5, subsample=0.8, random_state=42`. Se aplicó únicamente con undersampling por costo computacional.

7.4. Resultados comparativos

Cuadro 8: Comparación de modelos y estrategias de balanceo

Modelo	Recall	Precision	F1	ROC-AUC	PR-AUC
RF · class_weight	0.7653	0.0375	0.0716	0.8183	0.0767
GB · undersampling	0.2622	0.1011	0.1460	0.8183	0.0755
RF · undersampling	0.2745	0.1026	0.1494	0.8175	0.0774
LR · class_weight	0.6832	0.0411	0.0775	0.7992	0.0719
LR · undersampling	0.3056	0.0903	0.1394	0.7952	0.0715




Figura 8: Curvas ROC y Precisión-Recall del mejor modelo sobre validación.

7.5. Estrategia elegida y justificación

Se seleccionó `class_weight='balanced'` sobre **Random Forest** como estrategia y modelo definitivos por tres razones concretas:

1. **Recall superior:** detectó el 76.5 % de los accidentes reales, casi el triple que cualquier modelo con undersampling (máximo 27.5 %). En aplicaciones de seguridad pública, maximizar el recall es prioritario porque el costo de no detectar un accidente supera ampliamente el de generar una falsa alarma.
2. **ROC-AUC competitivo:** empató con el mejor ROC-AUC general (0.8183) sin necesidad de modificar los datos de entrenamiento, lo que elimina el riesgo de sesgos por re-muestreo.
3. **Eficiencia computacional:** `class_weight` no genera ni elimina filas, reduciendo el tiempo de entrenamiento frente a técnicas de re-muestreo como SMOTE o undersampling agresivo.

8. Modelo Final, Umbral y Validación

8.1. Selección del umbral de decisión

El umbral por defecto de 0.5 asume que ambos tipos de error tienen el mismo costo, lo que no es válido en este problema. Se evaluaron tres criterios de selección sobre el conjunto de validación:

Cuadro 9: Criterios de selección del umbral de decisión

Criterio	Umbral	Recall	Precision	F ₂
Máximo F ₁	0.847	0.2406	0.1095	0.1941
Máximo F₂	0.734	0.3984	0.0786	0.2197
Recall ≥ 0.70	0.552	0.7162	0.0415	0.1686

Se seleccionó el criterio de **máximo F₂** con umbral = 0,734, definido como:

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}, \quad \beta = 2$$

Con $\beta = 2$ el recall vale el doble que la precisión. Esta ponderación formaliza el criterio de negocio: no detectar un accidente (falso negativo) tiene un costo social y operativo mayor que generar una alerta innecesaria (falso positivo). El criterio recall ≥ 0,70 fue descartado por ser arbitrario; el umbral de máximo F_1 fue descartado porque sacrifica demasiado recall (24 %) en favor de una precisión marginalmente mayor.

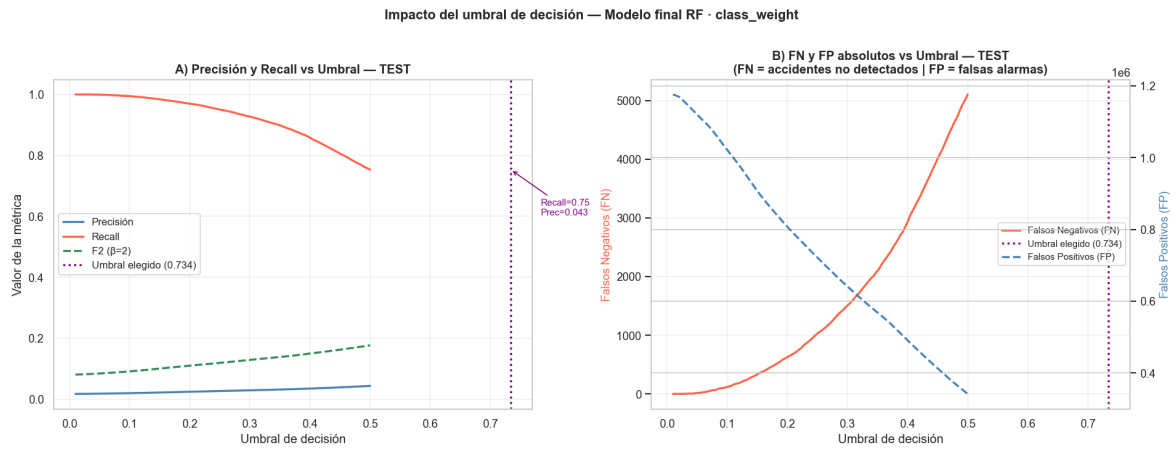


Figura 9: Impacto del umbral de decisión sobre Precisión, Recall, F₁ y F₂ — modelo RF con `class_weight='balanced'`. La línea vertical indica el umbral seleccionado (0.734).

Esta elección es además robusta desde la perspectiva operativa. Asumiendo que el costo de un falso negativo es 10 veces mayor que el de un falso positivo ($C_{FN}/C_{FP} = 10$), el umbral que minimiza el costo total esperado converge en la misma región que el criterio F₂, validando la decisión tanto estadística como operativamente.




Figura 10: Costo total de negocio en función del umbral de decisión ($C_{FN}/C_{FP} = 10$). El mínimo coincide con la región del umbral F_2 seleccionado.

8.2. Métricas finales sobre test

Con el umbral fijado en 0.734, el modelo se evaluó por **primera y única vez** sobre el conjunto de test, cronológicamente posterior a todo el proceso de selección.

Cuadro 10: Métricas finales del modelo sobre el conjunto de test

Métrica	Modelo final	Baseline
Accuracy	0.9282	0.9828
Precision	0.0944	0.0000
Recall	0.3687	0.0000
F1	0.1503	0.0000
F_2 ($\beta = 2$)	0.2331	0.0000
ROC-AUC	0.8110	0.5000
PR-AUC	0.0863	0.0151

El modelo detecta el **36.9 %** de los accidentes reales con una tasa de falsa alarma del 6.2 %. Frente al baseline, supera en todas las métricas relevantes para la clase positiva. La caída en accuracy respecto al baseline es esperada y deseable: el modelo ahora sí genera predicciones positivas, lo que inevitablemente reduce la exactitud global.

8.3. Matriz de confusión




Figura 11: Matriz de confusión del modelo final sobre test (umbral = 0,734).

Cuadro 11: Valores absolutos de la matriz de confusión e interpretación operativa

Categoría	Cantidad	Interpretación operativa
Verdaderos negativos (VN)	1 105 053	Horas-barrio sin accidente correctamente no alertadas
Falsos positivos (FP)	73 063	Alertas innecesarias — bajo costo operativo
Falsos negativos (FN)	13 038	Accidentes no detectados — error más crítico
Verdaderos positivos (VP)	7 613	Accidentes correctamente anticipados

8.4. Importancia de variables




Figura 12: Top 20 variables más importantes según reducción de impureza Gini (Random Forest).

Las variables históricas por barrio (`tasa_hist_barrio`, `acc_hist_acum`) dominan la importancia del modelo, lo que es coherente con la naturaleza del problema: la accidentalidad futura de un barrio está fuertemente correlacionada con su accidentalidad pasada. Las variables cíclicas de hora confirman la relevancia de los patrones temporales identificados en el EDA. Las variables climáticas de precipitación y visibilidad también aportan señal discriminativa. Ninguna variable presenta una dominancia sospechosa que sugiera fuga de información no detectada.

8.5. Validación cruzada temporal

La validación con `TimeSeriesSplit` (5 folds) sobre el 85 % del dataset confirmó la estabilidad del modelo. Se usó `TimeSeriesSplit` en lugar de `KFold` estándar porque este último mezclaría datos de distintos períodos, introduciendo fuga temporal.

Cuadro 12: Resultados promedio de la validación cruzada temporal (5 folds)

Métrica	Media	Desv. estándar	CV (%)
ROC-AUC	0.8199	0.0028	0.34 %
PR-AUC	0.0762	0.0009	1.18 %
Recall	0.3797	0.0128	3.37 %
F1	0.1363	0.0039	2.86 %
Precision	0.0831	0.0033	3.97 %

El coeficiente de variación (CV) fue inferior al 4 % en todas las métricas, indicando alta estabilidad temporal. Los resultados de la validación cruzada son consistentes con los de la partición temporal fija, descartando sobreajuste al período de test.




Figura 13: Evolución de métricas por fold en la validación cruzada temporal.

9. Caso de Uso Propuesto y Limitaciones

9.1. Caso de uso: sistema de alerta preventiva diaria

El modelo fue diseñado para operar como un **sistema de alerta preventiva diaria** para la Secretaría de Movilidad de Medellín. Cada mañana, el sistema consumiría los datos climáticos pronosticados para las próximas 24 horas y generaría automáticamente un reporte con el *Top-N* de combinaciones (barrio, franja horaria) de mayor probabilidad de accidente.

El flujo operativo propuesto sería el siguiente:

1. **Ingesta automática:** cada noche se descargan los pronósticos climáticos horarios por barrio para el día siguiente.
2. **Construcción de features:** se calculan las variables temporales, cíclicas e históricas (estas últimas disponibles sin fuga porque son datos del pasado).
3. **Inferencia:** el modelo genera probabilidades de accidente para cada combinación (barrio, hora).
4. **Filtrado por umbral:** se aplica el umbral 0.734 para clasificar alertas.
5. **Reporte:** se entrega a la Secretaría un listado priorizado y un mapa de calor interactivo con los sectores de mayor riesgo por franja horaria.

El sistema entregaría a la Secretaría un listado priorizado con las combinaciones (barrio, hora) de mayor riesgo, ordenadas por probabilidad descendente. Por ejemplo, para un día típico de operación el reporte incluiría los 10 barrios con mayor probabilidad predicha de accidente por franja horaria, junto con la probabilidad asociada y una etiqueta de alerta (1 = alerta activa, umbral = 0,734).

Las aplicaciones operativas concretas incluyen:

- **Asignación preventiva de agentes:** concentrar agentes de tránsito en los barrios y horas identificados como de alto riesgo, optimizando el uso de un recurso siempre limitado.
- **Ajuste dinámico de semáforos:** modificar los tiempos de ciclo en corredores críticos durante las franjas de alto riesgo predicho.
- **Campañas focalizadas:** diseñar campañas de prevención vial dirigidas a los barrios con mayor accidentalidad predicha, en lugar de campañas masivas de baja efectividad.
- **Integración con despacho:** conectar las salidas del modelo con el sistema de asignación de patrullas de la Secretaría para automatizar parcialmente la distribución de recursos.
- **Monitoreo de deriva:** comparar semanalmente las alertas emitidas con los ac-

cidentes realmente ocurridos para detectar degradación del modelo y activar el reentrenamiento.

9.2. Limitaciones

Cuadro 13: Limitaciones identificadas y su impacto operativo

Limitación	Descripción e impacto
Deriva temporal (<i>concept drift</i>)	Los patrones de movilidad y accidentalidad cambian con el tiempo: obras viales, nuevos desarrollos urbanos, pandemias o cambios en el transporte público alteran las relaciones aprendidas por el modelo. Sin reentrenamiento periódico, el rendimiento se degrada silenciosamente. Se recomienda un pipeline de reentrenamiento mensual con ventana deslizante.
Sesgo de reporte	Solo se registran accidentes formalmente reportados a la autoridad. Los incidentes menores (choques sin lesionados, daños leves) frecuentemente no se reportan, generando ruido en la variable objetivo y subestimando la accidentalidad real en ciertos barrios.
Interpretabilidad	Random Forest es un modelo de caja negra. Un operador de la Secretaría no puede entender por qué el modelo alerta sobre un barrio específico en una hora concreta. Para decisiones de política pública se recomienda complementar con valores SHAP que expliquen cada predicción individual en términos de sus features más influyentes.
Cobertura climática	Las combinaciones (barrio, hora) sin datos climáticos quedan excluidas del modelo. Si el proveedor de datos climáticos falla, el sistema no puede operar. Se recomienda implementar imputación de respaldo con datos de estaciones meteorológicas oficiales.
Precisión baja	Aproximadamente el 90 % de las alertas son falsas alarmas (Precision $\approx 9,4$ %). Esto es aceptable en prevención vial, donde el costo de una falsa alarma es bajo, pero debe comunicarse claramente a los operadores para evitar fatiga de alertas y pérdida de confianza en el sistema.

9.3. Variables externas que mejorarían el modelo

- **Flujo vehicular en tiempo real** (Waze API, Google Maps Platform): captura la congestión real por zona y hora, que es el predictor más directo de accidentalidad.
- **Eventos masivos**: conciertos, partidos de fútbol y marchas generan picos de tráfico localizados que el modelo no puede anticipar con las variables actuales.
- **Obras y cierres viales activos**: redirigen flujos y crean puntos de riesgo temporales no reflejados en el historial del barrio.
- **Calendario escolar**: los períodos académicos modifican sistemáticamente los patrones de movilidad matutina en zonas residenciales.
- **Estado del pavimento y señalización**: datos de mantenimiento vial por barrio permitirían capturar factores de riesgo de infraestructura.
- **Índice de iluminación vial**: la accidentalidad nocturna está relacionada con la calidad del alumbrado público, información disponible en algunos sistemas de gestión municipal.

10. Conclusiones y Trabajo Futuro

10.1. Conclusiones

La predicción de accidentalidad vial por barrio y hora es un problema de alta complejidad práctica, caracterizado por un desbalance extremo entre clases (1:65), dependencia temporal intrínseca de los datos y la necesidad de evitar fuga de información en cada etapa del pipeline.

Los hallazgos principales del trabajo son los siguientes:

1. **La elección de métricas define el problema.** Un modelo que predice siempre la clase mayoritaria obtiene 98 % de accuracy pero detecta cero accidentes. Esta paradoja demuestra que en escenarios desbalanceados la accuracy es una métrica inútil. Las métricas adecuadas son Recall, F_2 , ROC-AUC y PR-AUC, que miden efectivamente la capacidad de detectar la clase minoritaria.
2. **El historial del barrio es la señal predictiva dominante.** Las variables `tasa_hist_barrio` y `acc_hist_acum`, calculadas sin fuga temporal mediante `shift(1).expanding()`, concentran la mayor parte de la importancia del mo-

delo. Esto confirma que la accidentalidad tiene una componente espacial estable que persiste en el tiempo.

3. **La codificación cíclica es necesaria, no opcional.** Sin la transformación seno/coseno, los modelos lineales perciben una discontinuidad artificial entre la hora 23 y la hora 0, degradando la representación de los patrones diarios que el EDA mostró como fundamentales.
4. **El balanceo por pesos supera al undersampling en este contexto.** `class_weight='balanced'` alcanzó un Recall de 76.5 % en validación, casi el triple que cualquier modelo con undersampling, con el mismo ROC-AUC y menor costo computacional. La estrategia de balanceo resultó más determinante que la elección del algoritmo.
5. **El umbral es tan importante como el modelo.** Ajustar el umbral de 0.5 a 0.734 mediante el criterio F_2 alineó el modelo con el costo real de cada tipo de error. Esta decisión no requiere reentrenar el modelo y tiene un impacto operativo directo en cuántos accidentes se detectan.
6. **El modelo es estable en el tiempo.** El coeficiente de variación del ROC-AUC en validación cruzada temporal fue inferior al 0.4 %, y los resultados de la partición fija y la validación cruzada son consistentes entre sí. Esto descarta sobreajuste al período de test y da confianza en la generalización del modelo a datos futuros.
7. **El sistema es operativamente viable.** La propuesta de alerta diaria es técnicamente implementable con los datos disponibles, tiene un caso de negocio claro para la Secretaría de Movilidad y un modelo de costo que justifica la priorización del recall sobre la precisión.

10.2. Trabajo futuro

- **Incorporar datos de flujo vehicular en tiempo real.** La congestión es el predictor más directo de accidentalidad y actualmente no está disponible en el dataset. La integración con APIs de tráfico (Waze, Google Maps) podría incrementar sustancialmente la precisión del modelo.
- **Explorar modelos secuenciales.** Arquitecturas como LSTM o Temporal Fusion Transformer capturan dependencias temporales de largo plazo que Random Forest no puede modelar. Podrían mejorar la predicción en barrios con patrones de accidentalidad cíclicos complejos.

- **Implementar explicabilidad con SHAP.** Los valores SHAP permitirían a un operador no técnico de la Secretaría entender por qué el modelo alerta sobre un barrio específico: “este barrio fue alertado principalmente porque llueve y es viernes a las 18h, que históricamente concentra accidentes”. Esto aumenta la confianza operativa en el sistema.
- **Diseñar un pipeline de reentrenamiento continuo.** Con una ventana deslizante mensual, el modelo se actualizaría automáticamente incorporando los datos más recientes y descartando los más antiguos, mitigando la deriva temporal sin intervención manual.
- **Evaluar el impacto operativo real.** El siguiente paso natural es un piloto controlado con la Secretaría de Movilidad de Medellín: durante un período de prueba, comparar la efectividad de la asignación de agentes guiada por el modelo frente a la asignación tradicional basada en experiencia del operador.
- **Explorar modelos de costos explícitos.** En lugar de ajustar el umbral post-entrenamiento, es posible incorporar directamente la matriz de costos en la función de pérdida del modelo mediante *cost-sensitive learning*, lo que podría mejorar el Recall sin sacrificar tanto la Precision.